Triagem de Patologia Cardíaca Pediátrica com Dados de Encaminhamento: Comparação de Classificadores e Controle de Vazamento de Dados

Caio Moreira Bovo, Pedro Henrique Santana, Rafael Alencar Delfino, Yuri Resende Camargo
Mineração de Dados – Grupo 10
Universidade Federal de Goiás (UFG)

***Resumo*—Este trabalho investiga a triagem automática de patologia cardíaca pediátrica (0 a 19 anos) a partir dos dados de encaminhamento a um serviço especializado. Sobre o conjunto UCMF, com 11.470 pacientes após a limpeza, formulamos uma tarefa de classificação binária (Normal $\times$ Anormal) e excluímos o atributo Sopro, que caracteriza vazamento de dados. Comparamos um baseline de Regressão Logística com Árvore de Decisão, Random Forest e Gradient Boosting, em validação cruzada aninhada estratificada, com todo o pré-processamento ajustado apenas no treino. A Random Forest obteve AUC-ROC de 0,802, contra 0,787 do baseline, e reduziu a taxa de erro de 26,3% para 25,6%: diferença pequena, mas significativa pelos testes 5$\times$2cv (p = 0,018 e 0,036). Com o Sopro, a AUC chegaria a 0,953, o que mostra o tamanho do vazamento. Os motivos de encaminhamento são os atributos mais informativos, e o modelo não detecta 41,0% dos casos anormais no limiar padrão.**

***Palavras-chave*—classificação, cardiologia pediátrica, vazamento de dados, validação cruzada aninhada, aprendizado de máquina**

I. Introdução

Grande parte das crianças encaminhadas a um ambulatório de cardiologia pediátrica não tem doença cardíaca: os encaminhamentos por sopro inocente, pareceres pré-operatórios e check-ups ocupam a agenda de especialistas escassos. Uma ferramenta que estime, *antes* da consulta, a probabilidade de patologia ajudaria a priorizar quem deve ser atendido primeiro.

O objetivo deste trabalho é uma tarefa de **classificação binária**: prever se o paciente terá diagnóstico *Normal* ou *Anormal* a partir de dados demográficos, antropométricos, sinais vitais, histórico e motivos de encaminhamento. Como a classe de interesse é a Anormal, o erro mais grave é o falso negativo: uma criança doente classificada como saudável.

A contribuição é metodológica e prática: (i) identificamos e medimos o vazamento de dados causado pelo atributo Sopro; (ii) avaliamos quatro classificadores com um protocolo sem vazamento (validação aninhada e pré-processamento dentro do pipeline), com teste estatístico de comparação; e (iii) interpretamos os erros e os atributos mais relevantes no contexto clínico.

II. Dados e Análise Exploratória

O conjunto UCMF, fornecido no estudo de caso da disciplina, reúne atendimentos de cardiologia pediátrica, concentrados entre 2003 e 2010, de pacientes de 0 a 19 anos. Após a limpeza descrita na Seção III, restaram 11.470 instâncias e 21 atributos de entrada (Tabela I). A variável-alvo indica ausência ou presença de patologia cardíaca, com desbalanceamento leve: 57,3% Normal e 42,7% Anormal.

Tabela I
Características do conjunto após a limpeza

Característica	Valor
Instâncias (bruto $\rightarrow$ limpo)	12.873 $\rightarrow$ 11.470
Atributos de entrada (antes da codificação)	21
Classe Normal / Anormal	57,3% / 42,7%
Ausentes: Idade	6,7%
Ausentes: IMC	33,9%
Ausentes: Pressão arterial (PAS/PAD)	55,5%
Ausentes: Frequência cardíaca	6,2%
Ausentes: Motivo 2	22,1%
Ausentes: PPA	81,9%
Ausentes: HDA (histórico)	25,9%

As ausências são o principal problema de qualidade. A pressão arterial falta em 55,5% dos registros, e a classificação de hipertensão (PPA) em 81,9%, porque a planilha de origem registrava erro de fórmula ou "Não Calculado". A ausência não é aleatória: a pressão raramente é medida em lactentes. Por isso, em vez de descartar as variáveis, mantivemos indicadores de ausência.

Vazamento de dados. A análise bivariada da etapa anterior (A1) mostrou que o Sopro tem associação muito acima dos demais atributos com o alvo (V de Cramér de 0,84, contra 0,46 do segundo colocado; Fig. 1). Entre os pacientes com sopro sistólico, 95,9% são Anormais; sem sopro, apenas 10,1%. O Sopro é um achado do exame físico feito pelo próprio cardiologista, na mesma consulta que define o diagnóstico. Um modelo que o usa estaria "lendo" a conclusão do médico, e não fazendo triagem antes da consulta, o que caracteriza vazamento de dados [1]. O atributo foi **excluído** da análise principal; mantivemos um cenário com ele apenas para medir o tamanho do efeito.

III. Metodologia

Limpeza. Partimos do arquivo bruto (12.873 registros) e aplicamos as 34 regras da A1: remoção de duplicatas e de registros sem rótulo, recálculo da idade a partir das datas

Código, resultados e instruções de reprodução (`random_state = 42`): https://github.com/Caio424/Trabalho_DataMining.

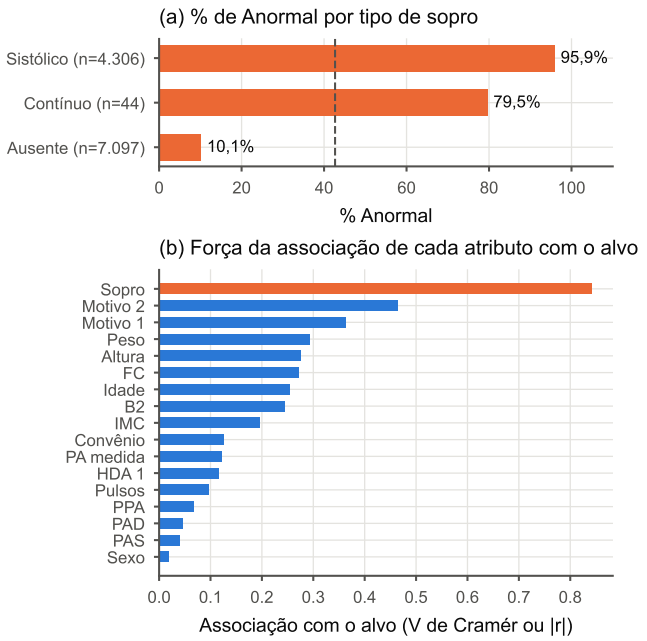


Figura 1. Evidência de vazamento. (a) Proporção de Anormais por tipo de sopro; a linha tracejada é a proporção geral. (b) Associação de cada atributo com o alvo na análise bivariada da A1; o Sopro destoa de todos os demais.

e do IMC a partir de peso e altura, e anulação de valores fisiologicamente impossíveis segundo faixas amplas de plausibilidade baseadas na OMS [2], em Fleming *et al.* [3] e em Flynn *et al.* [4]. Nenhum valor é imputado nessa etapa.

Atributos e transformações. Usamos idade, IMC, pressão sistólica e diastólica, frequência cardíaca (FC), sexo, convênio, pulsos, segunda bulha (B2), os dois motivos de encaminhamento, a PPA ordinal e sete indicadores de sintoma derivados do histórico (HDA). Identificador, datas, peso e altura foram removidos, pois a informação está na idade e no IMC. Todas as transformações que aprendem com os dados ficam dentro de um *pipeline* e são reajustadas em cada partição de treino: logaritmo nas variáveis assimétricas (IMC, PAS, FC), imputação pela mediana com indicador de ausência, padronização (z-score) e codificação one-hot, com categorias raras ($n < 30$) agrupadas. Assim, nenhuma estatística do conjunto de teste participa do ajuste.

Protocolo de validação. Com 11.470 instâncias, seguimos a recomendação de validação cruzada estratificada em 10 partições [5], na forma *aninhada*: em cada partição externa, uma validação interna estratificada de 5 partições escolhe os hiperparâmetros por busca em grade (critério AUC-ROC), e o modelo final é avaliado na partição externa, nunca vista. Cada instância é avaliada exatamente uma vez. Como a base não tem identificador de paciente, repetimos a avaliação com partição agrupada por data de nascimento e sexo, para verificar se possíveis retornos do mesmo paciente vazavam entre treino e teste. Nos experimentos de desbalanceamento e de partição agrupada, para reduzir o custo, os hiperparâmetros foram fixados nos mais escolhidos pela busca aninhada. Como essa escolha viu as mesmas partições, esses experimentos são comparados apenas entre si, a partir da linha *sem tratamento* da Tabela III, e não com a Tabela II.

Métricas. Relatamos média e desvio-padrão, nos 10 folds, de acurácia, acurácia balanceada, precisão, recall (sensibilidade), especificidade, F1, AUC-ROC e AUC-PR. Para triagem, o recall da classe Anormal é a métrica mais importante; a AUC-ROC mede a capacidade de ordenar pacientes por risco independentemente do limiar.

Algoritmos. A Regressão Logística é o baseline simples ($C \in \{0{,}01; 0{,}1; 1; 10\}$). Os modelos complexos são a Árvore de Decisão (profundidade e tamanho mínimo da folha), a Random Forest [6] (300 árvores; profundidade, tamanho da folha e fração de atributos) e o Gradient Boosting baseado em histogramas [7], [8] (taxa de aprendizado, profundidade e regularização L2). Uma classe majoritária serve de piso de referência. Implementação em scikit-learn [9] e imbalanced-learn [10].

Desbalanceamento. Para o baseline e o melhor modelo complexo, comparamos sem tratamento, pesos por classe, SMOTE [11] e subamostragem aleatória. A reamostragem ocorre somente no treino, dentro do pipeline. Também analisamos o efeito do limiar de decisão.

Comparação estatística. Comparamos o baseline e o melhor modelo complexo com o teste t 5×2cv de Dietterich [12], sobre a taxa de erro, com $\alpha = 0{,}05$ e 5 graus de liberdade; em cada uma das 10 execuções, os hiperparâmetros são reajustados no treino. Como a estatística t usa apenas a diferença da primeira execução, reportamos também o teste F combinado de Alpaydin [13], que usa as 10 diferenças. A importância dos atributos foi medida por permutação nos folds de teste (queda da AUC-ROC), sobre as colunas originais. O experimento completo levou cerca de 48 minutos.

IV. Resultados e Discussão

Comparação dos modelos. A Tabela II e a Fig. 2 mostram que todos os modelos superam com folga o piso da classe majoritária, mas ficam próximos entre si. A Random Forest obteve a maior AUC-ROC (0,802 $\pm$ 0,015), seguida de Gradient Boosting (0,801), Regressão Logística (0,787) e Árvore de Decisão (0,774). As curvas ROC e Precisão–Recall praticamente se sobrepõem. O teste t 5×2cv indica que a vantagem da Random Forest sobre o baseline, medida pela taxa de erro, é estatisticamente significativa (t = 3,44, p = 0,018); o teste F combinado, que não depende de uma única execução, confirma (F = 5,58, p = 0,036). O tamanho do efeito, porém, é modesto: a taxa de erro cai de 26,3% para 25,6%. Em outras palavras, o ganho é consistente entre partições, porém pequeno; a Regressão Logística, mais simples e interpretável, é uma alternativa quase equivalente. Os hiperparâmetros mais escolhidos foram C = 0,1 na Regressão Logística e max_depth = None, max_features = sqrt, min_samples_leaf = 5 na Random Forest. Os desvios-padrão baixos indicam estimativas estáveis entre as partições.

Tamanho do vazamento e dependência dos atributos. A Tabela III mostra que, com o Sopro, a AUC subiria para

Tabela II
DESEMPENHO NA VALIDAÇÃO CRUZADA ANINHADA (MÉDIA E DESVIO-PADRÃO EM 10 FOLDS; CENÁRIO SEM SOPRO; LIMIAR 0,5). EM NEGRITO, O MELHOR VALOR ENTRE OS MODELOS TREINADOS

Modelo	Acur.	Ac. bal.	Prec.	Recall	Espec.	F1	AUC-ROC	AUC-PR
Classe majoritária	0,573 (0,000)	0,500 (0,000)	0,000 (0,000)	0,000 (0,000)	1,000 (0,000)	0,000 (0,000)	0,500 (0,000)	0,427 (0,000)
Regressão Logística	0,738 (0,011)	0,719 (0,012)	0,745 (0,018)	0,587 (0,018)	0,850 (0,012)	0,656 (0,016)	0,787 (0,012)	0,759 (0,018)
Árvore de Decisão	0,729 (0,018)	0,709 (0,019)	0,735 (0,027)	0,572 (0,028)	0,846 (0,018)	0,643 (0,026)	0,774 (0,018)	0,734 (0,024)
Random Forest	**0,746 (0,014)**	**0,726 (0,014)**	**0,761 (0,021)**	0,590 (0,017)	**0,862 (0,013)**	0,665 (0,018)	**0,802 (0,015)**	0,770 (0,021)
Gradient Boosting	0,745 (0,014)	0,726 (0,013)	0,758 (0,026)	**0,592 (0,015)**	0,859 (0,019)	**0,665 (0,016)**	0,801 (0,015)	**0,771 (0,022)**

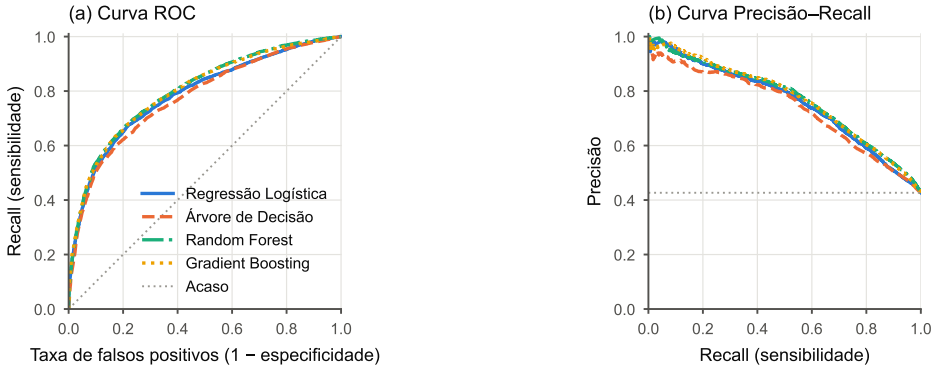


Figura 2. Curvas ROC e Precisão–Recall com as previsões fora da amostra dos 10 folds externos (cenário sem Sopro). A linha pontilhada indica o desempenho ao acaso.

Tabela III
ANÁLISE DE ABLAÇÃO: ATRIBUTOS, DESBALANCEAMENTO E VALIDAÇÃO AGRUPADA (MÉDIAS EM 10 FOLDS)

	Regressão Logística			Random Forest		
Configuração	AUC	Rec.	F1	AUC	Rec.	F1
Atributos						
Com Sopro (vazamento)	0,945	0,871	0,910	0,953	0,875	0,912
Sem Sopro (principal)	0,787	0,587	0,656	0,802	0,590	0,665
Sem Sopro e B2	0,772	0,572	0,641	0,788	0,575	0,649
Sem Sopro e Motivos	0,697	0,412	0,507	0,722	0,450	0,541
Desbalanceamento						
Sem tratamento	0,787	0,587	0,656	0,802	0,591	0,665
Pesos por classe	0,787	0,638	0,674	0,802	0,642	0,682
SMOTE	0,787	0,635	0,675	0,802	0,622	0,675
Subamostragem	0,787	0,638	0,675	0,801	0,653	0,684
Validação						
Agrupada por paciente	0,788	0,587	0,657	0,801	0,591	0,664

0,945 (Regressão Logística) e 0,953 (Random Forest), e o recall para cerca de 0,875. Esse salto de 0,15 na AUC é o desempenho "emprestado" do diagnóstico médico, que não estaria disponível no momento da triagem. Os motivos de encaminhamento são os atributos individualmente mais importantes: sem eles, a AUC cai para 0,697 e 0,722, mas cerca de 74% da discriminação acima do acaso permanece. A B2, outro achado de ausculta, pesa bem menos: sem ela, a AUC fica em 0,772 e 0,788.

Desbalanceamento e limiar. Como o desbalanceamento é leve, nenhuma estratégia altera a AUC: a ordenação dos pacientes por risco é a mesma. O que muda é o ponto de corte efetivo. Na Random Forest, partindo da linha sem tratamento (recall 0,591, especificidade 0,861), os pesos por classe elevam o recall para 0,642 e a subamostragem para 0,653, com queda da especificidade para 0,821 e 0,809. O ajuste direto do limiar é mais controlável: nas previsões fora da amostra, baixar o limiar de 0,5 para 0,3 reduz os doentes não detectados de 2.008 para 853 (58% a menos, recall 0,826), ao custo de aumentar os falsos alarmes de 905 para 2.814 (precisão 0,589). Em triagem, em que o falso negativo é o erro caro, um limiar mais baixo é preferível. A escolha exata, porém, é uma decisão clínica sobre a capacidade de atendimento, e não um parâmetro estatístico.

Pacientes repetidos. Com a partição agrupada, a AUC foi 0,788 e 0,801, igual à da partição comum (Tabela III). Não há indício de vazamento por retorno do mesmo paciente.

Análise dos erros. No limiar padrão, a Random Forest classifica corretamente 5.671 Normais e 2.886 Anormais, mas deixa passar 2.008 pacientes doentes (41,0% dos Anormais; Fig. 3a). O perfil desses erros é revelador. Os verdadeiros positivos são, em geral, lactentes (idade mediana de 1,1 ano), encaminhados por suspeita de cardiopatia (66%). Os falsos negativos são crianças mais velhas (mediana de 4,6 anos), encaminhadas majoritariamente para parecer cardiológico (59%), um perfil indistinguível do dos verdadeiros negativos (5,3 anos; 67% de parecer). Os falsos positivos são o espelho: lactentes com suspeita que se revelaram normais. O modelo aprendeu, portanto, o padrão "bebê com suspeita", e falha nos casos em que a doença aparece num encaminhamento de rotina.

Atributos relevantes. Pela importância por permutação (Fig. 3b), os atributos mais relevantes são Motivo 2, Motivo

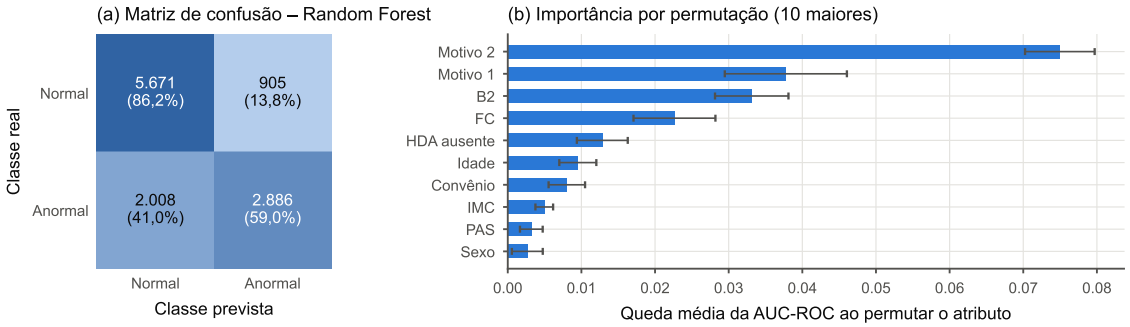


Figura 3. Random Forest no cenário sem Sopro. (a) Matriz de confusão das previsões fora da amostra, com o percentual em relação à classe real. (b) Queda média da AUC-ROC quando cada atributo é embaralhado no fold de teste; as barras indicam o desvio-padrão entre os folds.

1, B2 e FC. Os coeficientes da Regressão Logística apontam o mesmo sentido clínico. Como o modelo tem regularização L2 e codificação completa das categorias, $\exp(\beta)$ é uma razão de chances penalizada, indicativa do sentido e não da magnitude exata: o encaminhamento por sopro (3,72) e a B2 hiperfonética (2,79) aumentam a chance de patologia, e a B2 normal a reduz (0,18). A FC mediana é maior entre os verdadeiros positivos do que entre os verdadeiros negativos (100 contra 88 bpm), o que é coerente com a maior proporção de lactentes no primeiro grupo. A B2, assim como o Sopro, é um achado de ausculta. Ela foi mantida porque sua associação com o alvo é bem menor (V de 0,24, contra 0,84 do Sopro) e porque removê-la custa pouco (AUC de 0,788); para uma triagem estritamente anterior à consulta, o modelo sem B2 é a versão recomendada.

V. Conclusão

Formulamos a triagem de patologia cardíaca pediátrica como classificação binária e mostramos que, sem o atributo de vazamento, os dados de encaminhamento permitem discriminar moderadamente os pacientes (AUC-ROC de 0,802 com Random Forest). O ganho sobre a Regressão Logística é significativo, mas pequeno. Com ajuste do limiar, o modelo pode servir como apoio à priorização de agenda, mas não como substituto da avaliação clínica: mesmo com limiar reduzido, uma fração relevante dos doentes não é detectada.

As principais **limitações** são: (i) dados de um único serviço, concentrados entre 2003 e 2010, o que limita a generalização; (ii) a pressão arterial e a PPA têm muitas ausências; (iii) os motivos de encaminhamento refletem a suspeita de outro médico, e a B2 é um achado de exame, ainda que de peso pequeno; (iv) não há identificador real de paciente, e o agrupamento por data de nascimento e sexo é uma aproximação; (v) a validação é aleatória, e não temporal. Como **trabalhos futuros**, sugerimos validar o modelo em dados de outro período ou serviço, calibrar as probabilidades e definir o limiar com a equipe clínica a partir do custo de cada erro.

Declaração de uso de IA generativa

O assistente Claude (Anthropic), por meio da ferramenta Claude Code, foi usado para apoiar a implementação do código em Python (pipeline, experimentos, testes e figuras), organizar o protocolo experimental a partir do material da disciplina e redigir uma primeira versão deste texto. Os integrantes revisaram o código, conferiram os resultados e são responsáveis pelo conteúdo final.

Referências

[1] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, pp. 15:1–15:21, 2012.

[2] World Health Organization, "WHO child growth standards and growth reference data for 5–19 years," World Health Organization, Genebra, 2007.

[3] S. Fleming, M. Thompson, R. Stevens, C. Heneghan, A. Plüddemann, I. Maconochie, L. Tarassenko, and D. Mant, "Normal ranges of heart rate and respiratory rate in children from birth to 18 years of age: A systematic review of observational studies," *The Lancet*, vol. 377, no. 9770, pp. 1011–1018, 2011.

[4] J. T. Flynn *et al.*, "Clinical practice guideline for screening and management of high blood pressure in children and adolescents," *Pediatrics*, vol. 140, no. 3, p. e20171904, 2017.

[5] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *Proc. 14th Int. Joint Conf. on Artificial Intelligence (IJCAI)*, vol. 2, 1995, pp. 1137–1143.

[6] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[7] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.

[8] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30*, 2017, pp. 3146–3154.

[9] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[10] G. Lemaître, F. Nogueira, and C. K. Aridas, "Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning," *Journal of Machine Learning Research*, vol. 18, no. 17, pp. 1–5, 2017.

[11] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.

[12] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural Computation*, vol. 10, no. 7, pp. 1895–1923, 1998.

[13] E. Alpaydin, "Combined 5 x 2 cv F test for comparing supervised classification learning algorithms," *Neural Computation*, vol. 11, no. 8, pp. 1885–1892, 1999.